



فرم گزارش مرحله سوم مسئله پردازش تصویر

مسابقه هوش مصنوعی کی‌پُرده ۱۴۰۴

شماره گروه: 232

معرفی اعضای گروه

نام و نام خانوادگی: علی نجفی‌پور	نقش: ML	استان: زنجان
نام و نام خانوادگی: امیر ارسلان سیامرد	نقش: ML	استان: اصفهان
نام و نام خانوادگی: طاهای نادری‌پور	نقش: بک اند	استان: تهران
نام و نام خانوادگی: مهدی‌یار ذبیحی	نقش: بک اند	استان: تهران

تابلوخوان؛ سامانه Detection و Recognition متن فارسی در تصاویر طبیعی

فهرست مطالب

چکیده

۱. معرفی پروژه
۲. تعریف مسئله
۳. راحل نهایی
۴. روش‌ها و منابع ارزیابی
 - ۴.۱. PTDR
 - ۴.۲. PersianOCR-1K
 - ۴.۳. داده‌های test مرحله دوم
۵. انتخاب مدل‌های پایه و مسیر آموزش
 - ۵.۱. مدل‌های Detection و نتایج benchmark
 - ۵.۲. مدل‌های Recognition و نتایج benchmark
۶. مسیر بهبود مدل **Hezar**
 - ۶.۱. نتایج benchmark نسخه دوم
 - ۶.۲. آماده‌سازی dataset متنوع‌تر
 - ۶.۳. نتایج benchmark نسخه سوم
۷. مراحل آموزش مدل **Paddle Arabic V5**
 - ۷.۱. مقایسه مدل fine-tuned با مدل‌های پایه
 - ۷.۲. ارزیابی حروف اختصاصی فارسی
 - ۷.۳. آزمایش‌های تکمیلی پس از مدل منتخب
۸. خلاصه عملکرد **pipeline**
 - ۸.۱. flowchart نهایی
۹. بهبود **pipeline**
۱۰. نتیجه آزمایش **preprocessing**
۱۱. نمونه خروجی تولیدشده
 - ۱۱.۱. تصاویر و JSON متنی متناظر
۱۲. چالش‌ها و نحوه مواجهه با آن‌ها
۱۳. پیشنهاد‌های فاز بعد
۱۴. منابع و لینک‌ها

چکیده

تابلوخوان یک سامانه دو مرحله‌ای OCR فارسی برای تصاویر طبیعی است. مدل PP-OCRv6_medium_det نواحی متن را با Detection مشخص می‌کند و مدل arabic-train-v1، که از arabic_PP-OCRv5_mobile_rec fine-tuned شده است، متن هر ناحیه را می‌خواند. در ارزیابی مرحله دوم، مدل Detection به H-mean برابر با ۹۳/۷۹٪ رسید و مدل Recognition CER برابر با ۲۵/۹۷٪ ثبت کرد. ورودی بدون preprocessing عمومی به مدل داده می‌شود؛ برش perspective و بررسی کنترل‌شده جهت برای نواحی لازم انجام می‌شود. رابط FastAPI دو حالت OCR کامل و فقط Detection را ارائه می‌کند.

معرفی پروژه

تابلوخوان یک سامانه OCR فارسی برای استخراج متن از تصاویر واقعی است. این تصاویر می‌توانند شامل تابلوها، پوسترها، بسته‌بندی محصولات و نوشته‌هایی با زاویه، نور نامناسب یا پس‌زمینه شلوغ باشند. سامانه ابتدا محل نوشته‌ها را در تصویر پیدا می‌کند، هر ناحیه را با اصلاح زاویه به یک برش مستقیم تبدیل می‌کند و سپس متن فارسی آن را می‌خواند. خروجی نهایی شامل متن پیش‌بینی‌شده و مختصات هر ناحیه در تصویر است. هدف پروژه، ساخت مسیری ساده و قابل اجرا برای خواندن متن فارسی در شرایطی است که عکس ورودی ممکن است برای مدل‌های پایه موجود دشوار باشد.

این پروژه با انجام آزمایش‌هایی روی مدل‌های موجود Detection متن و Recognition متن، تلاش می‌کند با بهبود کیفیت و دقت آن‌ها، سامانه‌ای کاربردی برای ورودی‌های دشوار و غیرمنتظره ارائه دهد.

تعریف مسئله

هدف مسئله، طراحی یک سامانه دومرحله‌ای OCR فارسی برای استخراج متن از تصاویر واقعی با پس‌زمینه‌ها و محیط‌های پیچیده و متنوع است. در این معماری، مرحله نخست محل متن را با Detection مشخص می‌کند. در مرحله دوم، محتوای هر ناحیه Recognition و متن پیش‌بینی‌شده به عنوان خروجی ارائه می‌شود.

چالش اصلی این مسئله، نوشته‌هایی با fontهای خاص، زاویه‌های مختلف، contrast پایین، noise و موارد مشابه است که سامانه‌های OCR فارسی موجود را با مشکل مواجه می‌کنند.

راهنمای نهایی

برای Detection نواحی متن از مدل PP-OCrv6_medium_det استفاده کردیم.

برای Recognition متن از مدل arabic-train-v1 استفاده کردیم. این مدل، نسخه fine-tuned arabic_PP-OCrv5_mobile_rec برای متن فارسی است.

مدل Recognition طی چند مرحله با داده‌های مختلف fine-tune شد. این روند شامل جمع‌آوری و تولید dataset بر اساس نیاز هر مرحله، مقایسه نتایج و benchmark مدل‌ها و بررسی روش‌های preprocessing و postprocessing بود.

در pipeline نهایی، نواحی پیش‌بینی‌شده پس از برش و perspective correction به مدل Recognition فرستاده می‌شوند. بررسی جهت با Recognition مجدد برش‌های چرخیده و مقایسه confidence انجام می‌شود. متن منتخب همراه با موقعیت ناحیه در تصویر نمایش داده می‌شود.

روش‌ها و منابع ارزیابی

در این پروژه، مدل‌های پایه و fine-tuned را با datasetهای مشخص ارزیابی و نتایج آن‌ها را با یکدیگر مقایسه کردیم. در مجموع، برای ارزیابی Recognition از سه dataset و برای ارزیابی Detection از یک dataset استفاده کردیم.



dataset PTDR

بخش Test این dataset شامل تصاویر طبیعی است و برای ارزیابی Recognition استفاده شد.

منبع: <https://github.com/zobeirraisi/PTDR>

نمونه‌ای از PTDR


PTDR recognition examples



dataset PersianOCR-1K

این مجموعه شامل ۱۰۰۰ تصویر منتخب از dataset <https://huggingface.co/datasets/ordaktaktak/Persian-OCR-230k> است. تمرکز این مجموعه بیشتر بر تصاویر چاپی است.

PersianOCR-1K recognition examples



داده‌های test مرحله دوم

داده‌های مرحله دوم مسابقه کپی‌برد را annotation کردیم و برای benchmark‌های Detection و Recognition به کار بردیم.

نمونه annotated برای Recognition متن

Stage 2 recognition examples



نمونه annotated برای Detection متن



نکته: هیچ‌یک از نمونه‌های ارزیابی در هیچ مرحله‌ای از آموزش مدل‌ها استفاده نشدند.

dataset annotated مرحله دوم هیچ‌گاه در آموزش استفاده نشد.

بخش‌هایی از PTDR و Persian OCR در مراحل آموزش به کار رفتند، اما نمونه‌های آموزش از بخش‌های ارزیابی جدا بودند.

داده‌های آموزش با داده‌های Validation و Test هیچ اشتراکی نداشتند.

معیار اصلی ارزیابی بخش Recognition در این پروژه Character Error Rate یا CER بود. این معیار اختلاف متن پیش‌بینی‌شده و متن مرجع را در سطح نویسه محاسبه می‌کند. از آنجا که خروجی سامانه معمولاً شامل کلمات و عبارات‌های کوتاه فارسی است، CER بهبودهای جزئی مدل را بهتر از معیارهایی مانند Exact Match یا WER نشان می‌دهد. با این حال، برای ارزیابی کامل‌تر، WER و Exact Match نیز در کنار CER گزارش شدند.

انتخاب مدل‌های پایه و مسیر آموزش

در فایل مسئله چند مدل پیشنهاد شده بود. همه این مدل‌ها را با dataset های آماده شده benchmark کردیم.

مدل‌های پیشنهادی Detection متن

پیشنهادهای مسئله بر دو کتابخانه PaddleOCR و Hezar متمرکز بودند.

مدل‌های PaddleOCR

- PP-OCRv5_server_det
- PP-OCRv5_mobile_det
- det_Multilingual_PP-OCRv3
- مدل CRAFT از کتابخانه Hezar

در کنار مدل‌های معرفی شده، مدل زیر را نیز آزمودیم.

- PP-OCRv6_medium_det

نتایج در جدول زیر آمده است.

جدول ۱. مقایسه عملکرد مدل‌های Detection متن روی dataset annotated مرحله دوم

H-mean (F1)	Recall	Precision	Detection Model
93.79%	97.70%	90.19%	PP-OCRv6_medium_det
71.50%	67.96%	75.44%	PP-OCRv5_mobile_det
64.22%	69.25%	59.88%	PP-OCRv5_server_det
63.53%	57.18%	71.45%	det_Multilingual_PP-OCRv3 / PP-OCRv3_mobile_det

این ارزیابی روی ۶۰ تصویر و ۶۹۶ ناحیه متنی خوانا از dataset annotated مرحله دوم انجام شد. برای تطبیق نواحی پیش‌بینی شده و واقعی، آستانه Polygon IoU برابر با ۰/۵ در نظر گرفته شد.

نتایج نشان می‌دهند نسخه ۶ روی داده‌های ما عملکرد بهتری دارد. Precision این مدل بیشتر از ۹۰ درصد و H-mean آن حدود ۲۰ واحد درصد بیشتر از نسخه ۵ است.

بر همین اساس، مدل PP-OCRv6_medium_det را به عنوان مدل پایه Detection انتخاب کردیم.

مدل‌های پیشنهادی Recognition متن

مدل‌های PaddleOCR

- PP-OCRv5_server_rec
- arabic_PP-OCRv5_mobile_rec
- rec_arabic_PP-OCRv3
- مدل crnn-base-fa-v2 از کتابخانه Hezar

جدول‌های زیر WER، CER و Exact Match مدل‌های مختلف را روی dataset های ارزیابی مقایسه می‌کنند.

داده‌های مرحله دوم، ۶۹۶ نمونه

Exact Match ↑	WER ↓	CER ↓	Base Recognition Model
24.86%	60.89%	26.94%	arabic_PP-OCRv3_mobile_rec

Exact Match ↑	WER ↓	CER ↓	Base Recognition Model
27.30%	56.77%	28.02%	arabic_PP-OCRv5_mobile_rec
21.55%	66.94%	40.77%	crnn-base-fa-v2
0.00%	100.12%	98.34%	PP-OCRv5_server_rec

داده‌های ۹۳۸۸ PTDR نمونه

Exact Match ↑	WER ↓	CER ↓	Base Recognition Model
68.92%	32.73%	17.16%	arabic_PP-OCRv5_mobile_rec
65.38%	37.27%	18.31%	arabic_PP-OCRv3_mobile_rec
39.90%	77.26%	36.85%	crnn-base-fa-v2
1.42%	98.95%	97.84%	PP-OCRv5_server_rec

داده‌های ۱۰۰۰ PersianOCR-1K نمونه

Exact Match ↑	WER ↓	CER ↓	Base Recognition Model
49.60%	19.43%	4.76%	arabic_PP-OCRv5_mobile_rec
28.60%	30.32%	7.15%	arabic_PP-OCRv3_mobile_rec
26.90%	42.88%	16.75%	crnn-base-fa-v2
0.00%	99.86%	98.97%	PP-OCRv5_server_rec

مدل PP-OCRv5_server_rec روی زبان فارسی عملکرد مناسبی نداشت، زیرا مدل پایه برای فارسی آموزش ندیده بود.

مدل‌های عربی Paddle نسبت به مدل پایه Hezar عملکرد بهتری داشتند و گزینه‌های مناسب‌تری برای ادامه کار بودند.

عملکرد نسخه‌های ۳ و ۵ مدل عربی نزدیک بود. نسخه ۳ در داده‌های مرحله دوم اندکی بهتر بود، اما نسخه ۵ در دو dataset دیگر نتیجه بهتری داشت.

برای ادامه مسیر، دو روند آموزشی جدا و موازی در نظر گرفتیم.

• fine-tune مدل عربی نسخه ۵ برای بهبود Recognition متن فارسی

• بهبود و fine-tune مدل Hezar

دلیل ادامه کار روی مدل Hezar، با وجود نتایج ضعیف‌تر آن نسبت به مدل عربی، این بود که مدل Hezar فقط روی داده‌های چاپی فارسی آموزش دیده بود.

این مدل توانایی پایه‌ای در Recognition فارسی داشت، اما font‌های متنوع، پس‌زمینه‌های طبیعی، تصاویر بی‌کیفیت، noise و موارد مشابه را ندیده بود.

فرض ما این بود که fine-tune کافی و مناسب می‌تواند دقت آن را از مدل عربی بیشتر کند.

مسیر بهبود مدل Hezar

در نخستین گام fine-tune مدل Hezar، تصمیم گرفتیم آن را با داده‌های طبیعی و تصاویر واقعی آموزش دهیم؛ به همین دلیل از dataset PTDR استفاده کردیم.

این dataset شامل تصاویر طبیعی و مصنوعی است و برای شروع آموزش مدل انتخاب مناسبی به نظر می‌رسید.

از این dataset، ۲۰۰۰ نمونه برای Validation جدا کردیم. نمونه‌های باقی‌مانده را با پنج نوع data augmentation و تنظیمات زیر آماده کردیم.

Parameters	Probability	Method
زاویه تصادفی حدود ۳ تا ۱۵ درجه در دو جهت	20%	Rotation
جابجایی گوشه‌ها تا حدود ۱۵٪ اندازه تصویر	20%	Perspective
sigma=15	20%	Gaussian noise
شعاع 0.5–1.5	20%	Gaussian blur
ضریب 0.5–1.5	20%	Contrast

با افزودن تصاویر اصلی، آموزش روی ۴۷۹۹۶ نمونه انجام شد.

آموزش را با batch size برابر با ۱۲۸ و learning rate ۰/۰۰۰۰۱ آغاز کردیم.

عملکرد مدل تا epoch 15 روی داده‌های validation بهتر شد.

پس از epoch 15، نتایج validation در بازه‌ای محدود نوسان داشت، در حالی که training loss همچنان کاهش می‌یافت. این رفتار نشانهٔ overfitting مدل روی این dataset بود.

بهترین مدل در epoch 15 ثبت شد و آن را Hezar Fine-tuned V1 نامیدیم.

نتایج این مرحله در جدول زیر آمده است.

PersianOCR-1K CER	PTDR CER	Stage 2 CER	Model
16.75%	36.85%	40.77%	Hezar Base
17.72%	19.81%	42.05%	Hezar Fine-tuned V1

بهبود مدل روی PTDR به‌وضوح قابل مشاهده است.

در دو dataset دیگر، کاهش جزئی کیفیت مشاهده شد.

سپس نسخهٔ دوم این مدل را آموزش دادیم.

برای این مرحله، ترکیبی از داده‌های مصنوعی دشوار و داده‌های طبیعی در نظر گرفتیم.


در این مرحله از ۲۰ هزار نمونهٔ PTDR و ۸۰ هزار نمونهٔ مصنوعی استفاده کردیم.

داده‌های مصنوعی شامل ۲۰٪ کلمه، ۷۰٪ عبارت‌های ۲ تا ۶ کلمه‌ای و ۱۰٪ عدد بودند. JPEG و Rotation، Perspective، Noise، Blur و Compression نیز اعمال شدند.

Easier synthetic samples



Harder synthetic samples



نمونه‌هایی از داده‌های مصنوعی آموزش مدل Hezar نسخه ۲؛ ستون چپ شامل تصاویر خواناتر و ستون راست شامل نمونه‌های دشوار با blur، contrast پایین، پس‌زمینه شلوغ و perspective distortion است.

آموزش با learning rate ۰/۰۰۰۱ تا epoch 41 ادامه یافت. بهترین نتیجه در epoch 34 ثبت شد و پس از آن داده‌های validation بهبود بیشتری نشان ندادند.

نتایج benchmark مدل Hezar نسخه ۲

PersianOCR-1K CER	PTDR CER	Stage 2 CER	Model
17.72%	19.81%	42.05%	Hezar V1
9.36%	17.43%	33.87%	Hezar V2

نتایج نشان می‌دهند مدل در همه dataset‌های ارزیابی بهبود معناداری داشته است. در ادامه، روش‌های مختلفی را برای جلوگیری از overfitting مدل بررسی کردیم. learning rate را به ۰/۰۰۰۰۲ کاهش دادیم، اما پس از epoch ۳ بهبودی مشاهده نشد. آزمایش تکمیلی با learning rate ۰/۰۰۰۰۱ و weight decay ۰/۰۰۰۰۱ نیز بهبودی ایجاد نکرد. به همین دلیل، ادامه کار را بر متنوع‌تر کردن dataset متمرکز کردیم.

آماده‌سازی dataset متنوع‌تر

این مدل از نسخه ۲ شروع شد و روی dataset جدید و متنوع‌تری آموزش دید.

Train samples	Dataset source
15,000	PTDR
10,000	Previous synthetic data
25,000	Persian-OCR-230k
50,000	New synthetic data
100,000	Total

بخش validation شامل ۲۰۰۰ و بخش test شامل ۱۰۰۰ نمونه مجزا بود. در داده‌های مصنوعی جدید، سهم نمونه‌های دشوار با contrast پایین، noise، بافت و font‌های متنوع افزایش یافت.

داده‌های مصنوعی جدید شامل font‌ها، پس‌زمینه‌ها، رنگ‌ها، بافت‌ها و طول‌های متنوع بودند. blur، noise، JPEG compression، rotation، perspective distortion و contrast پایین نیز به تصاویر اضافه شد. در ۴۵٪ از نمونه‌ها، رنگ متن به رنگ پس‌زمینه نزدیک بود.

تا خواندن متن دشوارتر شود. ترکیب هدف کل dataset تقریباً شامل ۳۰٪ ساده، ۳۰٪ متوسط، ۳۵٪ سخت و ۵٪ بسیار سخت بود. متن‌ها نیز از ۲۰٪ تک‌کلمه، ۷۰٪ عبارتهای ۲ تا ۶ کلمه‌ای و ۱۰٪ عدد تشکیل شدند.

learning rate برابر با ۰/۰۰۰۰۱ بود.

پس از ۵ epoch، مدل دوباره دچار overfitting شد. بهترین نتیجه در ۵ epoch ثبت شد.

نتایج benchmark مدل Hezar نسخه ۳

PersianOCR-1K CER	PTDR CER	Stage 2 CER	Model
17.72%	19.81%	42.05%	Fine-tuned V1
9.36%	17.43%	33.87%	Fine-tuned V2
0.98%	15.38%	29.36%	Fine-tuned V3

نتایج در جدول زیر آمده است.

مراحل آموزش مدل عربی نسخه ۵

برای fine-tune مدل عربی، مجموعه‌ای شامل ۱۰۰'۰۰۰ نمونه آموزش تهیه کردیم. ترکیب آن شامل ۲۵'۰۰۰ نمونه از Persian-OCR-230k، تعداد ۱۵'۰۰۰ نمونه از PTDR و ۶۰'۰۰۰ نمونه مصنوعی جدید بود.

برای validation نیز ۱'۰۰۰ نمونه مجزا از Persian-OCR-230k و ۱'۰۰۰ نمونه مصنوعی در نظر گرفتیم. هیچ‌یک از داده‌های test Stage 2، بخش PTDR یا PersianOCR-1K Test dataset در آموزش و انتخاب checkpoint استفاده نشد.

در بخش مصنوعی، font، پس‌زمینه، رنگ، contrast، noise، blur، JPEG compression، rotation و perspective distortion را متنوع کردیم.

در انتخاب متن‌ها به حروف اختصاصی فارسی «گ»، «چ»، «پ» و «ژ» توجه کردیم و نمونه‌های حاوی این حروف را با سهم بیشتری در داده مصنوعی قرار دادیم؛ زیرا مدل پایه عربی این نویسه‌ها را کمتر از حروف مشترک فارسی و عربی دیده بود.

مدل عربی را با learning rate برابر با ۰/۰۰۰۰۱ به مدت ۵ epoch آموزش دادیم. بهترین checkpoint مربوط به epoch 2 بود که آن را ذخیره کردیم و با نام arabic-train-v1 به کار گرفتیم. در epoch‌های بعدی بهبود بیشتری مشاهده نشد و به نظر می‌رسید مدل به سمت overfitting می‌رود.

مدل منتخب در مقایسه با نسخه پایه، CER داده‌های مرحله دوم را از ۲۸/۰۲٪ به ۲۵/۹۷٪ و CER dataset PTDR را از ۱۷/۱۶٪ به ۱۴/۳۰٪ کاهش داد.

مقایسه مدل عربی fine-tuned با مدل پایه Paddle Arabic و Hezar V3

PersianOCR-1K CER	PTDR CER	Stage 2 CER	Model
4.76%	17.16%	28.02%	Paddle Arabic Base
0.98%	15.38%	29.36%	Hezar V3
4.29%	14.30%	25.97%	Paddle Arabic Fine-tuned V1

نتایج در جدول بالا آمده است.

بر این اساس، مدل fine-tuned عربی با نام arabic-train-v1 برای بخش Recognition pipeline نهایی انتخاب شد.

ارزیابی حروف اختصاصی فارسی

برای اندازه‌گیری اثر این نمونه‌گیری، متن مرجع و خروجی مدل را با Levenshtein edit distance هم‌تراز کردیم و Recall هر حرف را محاسبه کردیم. در مجموع سه مجموعه ارزیابی، تعداد ۱'۷۹۴ رخداد از حروف «گ»، «چ»، «پ» و «ژ» وجود داشت.

Recall مجموع این چهار حرف از ۵۷/۵۵٪ در مدل پایه به ۷۷/۵۴٪ در arabic-train-v1 رسید؛ یعنی ۲۱/۹۷ واحد درصد بهبود.

جدول ۱۰. مقایسه Recall حروف اختصاصی فارسی در مدل پایه و مدل fine-tuned

حرف	مدل پایه	arabic-train-v1	میزان بهبود
گ	۵۵/۵۴٪	۷۸/۳۳٪	۲۲/۷۹ واحد درصد
چ	۶۰/۲۱٪	۷۵/۳۳٪	۱۵/۱۲ واحد درصد
پ	۵۳/۲۹٪	۷۸/۶۹٪	۲۵/۴۰ واحد درصد
ژ	۴۷/۰۶٪	۶۸/۶۳٪	۲۱/۵۷ واحد درصد
مجموع	۵۵/۵۷٪	۷۷/۵۴٪	۲۱/۹۷ واحد درصد

افزایش Recall به‌تنهایی کافی نیست. Precision حرف «پ» از ۹۹/۰۱٪ به ۷۶/۶۴٪ کاهش یافت؛ یعنی مدل این حرف را بیشتر پیدا کرد، اما در برخی نمونه‌ها حروف دیگر را نیز به‌اشتباه «پ» خواند.

آزمایش‌های تکمیلی پس از مدل منتخب

سناریوی نخست، ادامه آموزش روی همان ترکیب ۱۰۰'۰۰۰ نمونه‌ای با داده‌های طبیعی و مصنوعی متنوع‌تر بود. آموزش تا epochهای بیشتر ادامه یافت. checkpoint epoch 13 CER dataset PTDR را از ۱۴/۳۰٪ به ۱۳/۹۱٪ و CER dataset PersianOCR-1K را از ۴/۲۹٪ به ۱/۸۹٪ کاهش داد، اما CER داده‌های مرحله دوم از ۲۵/۹۷٪ به ۲۹/۲۹٪ افزایش یافت. چون بهبود روی مجموعه‌های ثابت یکنواخت نبود، این checkpoint جایگزین مدل منتخب نشد.

سناریوی دوم، fine-tune هدفمند حروف «گ»، «چ»، «پ» و «ژ» بود. برای این آزمایش ۱۰'۰۰۰ نمونه مصنوعی حاوی این حروف را با ۱۰'۰۰۰ نمونه واقعی PTDR ترکیب کردیم تا مدل در کنار یادگیری حروف هدف، داده‌های عمومی را نیز مرور کند. آموزش با learning rate ۰/۰۰۰۰۰۰۵ و در epoch ۲ انجام شد.

این آموزش هدفمند پایدار نبود. CER به ۹۰/۹۱٪ روی داده‌های مرحله دوم، ۹۸/۸۲٪ روی PTDR و ۶۲/۷۸٪ روی PersianOCR-1K رسید. checkpoint حاصل رد شد و مدل arabic-train-v1 بدون تغییر حفظ شد.

به همین دلیل هیچ‌کدام از مدل‌ها فوق انتخاب نشدند.

خلاصه عملکرد pipeline


سامانه با FastAPI و Uvicorn روی نشانی 127.0.0.1:8000 اجرا می‌شود. کاربر در رابط وب یک یا چند تصویر را بارگذاری و حالت OCR کامل یا فقط Detection را انتخاب می‌کند. در حالت OCR کامل، پس از Detection نواحی و perspective correction برش‌ها، مدل arabic-train-v1 هر برش را می‌خواند. سپس برش ۱۸۰ درجه چرخانده و دوباره با Recognition خوانده می‌شود. برای برش‌های بلند، متن خالی یا متن بسیار کوتاه با confidence پایین، دو rotation ۹۰ درجه نیز با Recognition خوانده می‌شوند. نتیجه جایگزین تنها با حداقل سه نویسه، confidence حداقل ۰/۵۵ و افزایش confidence حداقل ۰/۱۲ پذیرفته می‌شود. خروجی در رابط نمایش داده می‌شود و تصاویر annotated و نتایج متنی JSON در پوشه results ذخیره می‌شوند.

جزء	پیداسازی فعلی	خروجی
رابط و API	FastAPI، HTML و Uvicorn	POST /ocr و POST /ocr/json
Detection متن	PP-OCRv6_medium_det روی gpu:0	چهارضلعی‌ها، امتیاز و ترتیب خواندن
اصلاح هندسی	OpenCV warpPerspective	برش مستقیم هر ناحیه
Recognition	arabic-train-v1 روی gpu:0	متن و confidence Recognition
پاسخ	JSON و JPEG کدگذاری شده با Base64	نمایش مستقیم در رابط وب

flowchart of the pipeline

TABLOKHAN OCR PIPELINE

Rotation candidates are recognized before their results are compared



No separate orientation model and no general image enhancement

بهبود pipeline

نتایج بررسی‌های انجام‌شده در جدول زیر آمده است. شماره موارد مطابق صورت مسئله حفظ شده است.

مورد	نتیجه بررسی و تصمیم
1. CRNN	سبک، ساده و مناسب ورودی با عرض متغیر است. در مسیر آزمایشی Hezar از CRNN استفاده شد، اما مدل نهایی Recognition arabic-train-v1 بر پایه معماری Paddle Arabic V5 است، چون در test‌های نهایی CER کمتری داشت.
2. CRAFT	برای متن‌های نامنظم و ناحیه‌بندی ریز مناسب است. آزمایش شد، اما به دلیل تفاوت دانه‌بندی با annotation جمله‌ای مرحله دوم و امتیاز پایین‌تر کنار گذاشته شد. مدل نهایی PP-Detection OCRv6_medium_det است.
3. حروف گ، ژ، پ و چ	مدل عربی پایه این حروف را کمتر از حروف مشترک فارسی و عربی دیده بود. راهکار اجرا شده، fine-tune روی داده فارسی و افزایش نمونه‌های حاوی این حروف بود. پیشنهاد بعدی، نمونه‌گیری هدفمند از خطاهای واقعی همین حروف و حفظ بخشی از داده‌های عمومی برای جلوگیری از overfitting است.
4. Resize	در مدل نهایی مقدار ذخیره‌شده Paddle یعنی $320 \times 48 \times 3$ حفظ شد. تغییر عرض در آزمایش‌ها نشان داد مقدار میانی بهتر از ۱۹۲ و ۷۶۸ است؛ بنابراین اندازه مدل نهایی تغییر نکرد.

نتیجه آزمایش preprocessing


برای arabic-train-v1 هیچ preprocessing عمومی به pipeline اضافه نشد. ورودی اصلی در سه مجموعه ارزیابی بهترین یا همسطح بهترین نتیجه را داشت.

dataset	ورودی اصلی CER	Sharpen CER	نتیجه
مرحله دوم، ۶۹۶ نمونه	۲۵/۹۷٪	۲۵/۹۷٪	برابری CER؛ ورودی اصلی حفظ شد
۹۳۸۸ PTDR، نمونه	۱۴/۳۱٪	۱۴/۴۳٪	ورودی اصلی بهتر بود
PersianOCR-1K، ۱۰۰۰ نمونه	۴/۳۴٪	۴/۳۵٪	ورودی اصلی بهتر بود

نمونه خروجی تولیدشده

این دو تصویر با pipeline نهایی شامل arabic-train-v1 و PP-OCRv6_medium_det روی GPU پردازش شدند. JSON متنی کامل هر تصویر مطابق قالب ذخیره‌سازی برنامه در زیر آمده است. ترتیب texts با شماره نواحی تصویر یکسان است؛ متن‌های اشتباه و خروجی‌های خالی بدون اصلاح حفظ شده‌اند.

تصاویر و JSON متنی متناظر
نمونه اول از داده‌های مرحله دوم



JSON متناظر با 10 ناحیه

```
[
  {
    "image": "101.jpg",
    "texts": [
      "تظامی مجلس اعلای",
      "صن طدهاند",
      "تکامل شخصیت محنون",
      "رمداول صدو 1",
      "صا بور مد وحیلد",
      "بعیت کمک",
      "دوهدشادسدن",
      "بلم تمیل",
      "ی",
      "پرقاطق نوری"
    ]
  }
]
```



```
[
{
"image": "photo_2026-09-06_02-35-19.jpg",
"texts": [
"وانهاده",
"۱",
"واقعیّت",
"ANDREW MATTHEWS",
"البرکامو",
"انتشارات تیلوار",
"ت",
"اسطوره سیزیف",
"3",
"جیمز نوربری",
"The First Man",
"عصیانگر",
"جام",
"سیمون دوبووار",
"Daddy-Long-Legs",
"ترجم امیر جلال الدیناعلم",
"درس هایی درباره داستان نویسی",
"ترجمعی اعبد روعال",
"BEING HAPPY!",
"طاعون",
"مجموعه داستانها",
"البرکامو",
"پاندای بزرگ وازدهای کوچک",
"لئونارد بشاب",
"AND THEN THERE WERE NONع",
"AGATHA CHRISTIE",
"البرکامو",
"برنامهریزی به روش بولت ژونال راینرکارول ترجمه رانجاری",
"SARAH",
"۱ هانس رزلینگ",
"Jean Webster",
"ترجمهی فرشت افسری",
"برگردان مهستی بحرینی",
"نازنین فیروزی",
"ALBERT CAMUS",
"البراک سینگر جور مار",
"بعظمس مسامیما",
"ترجمد",
"محسن سلیمانی",
"برگردانمهستی بحرینی",
"ANDERSEN",

```



```

"""
'
"ي",
"MEادA MASTERS",
"فرانتس کافکا",
"""
"حرن ه",
"age",
"BANTAM",
"مزم میوار"
]
}
]

```

شرح چالش‌ها و نحوه مواجهه با آنها

چالش	اقدام انجام‌شده	وضعیت
متن کم‌contrast، محو و بافت‌دار	افزایش سهم داده‌های سخت و متنوع و رد روش‌های preprocessing عمومی که CER را بدتر کردند	بهبود یافت، اما همچنان از خطاهای اصلی است
rotation ۱۸۰ و ۹۰ درجه	مقایسه کنترل‌شده جهت‌ها و پذیرش نتیجه جایگزین فقط با طول و افزایش confidence کافی	برای تصاویر عمودی بهتر شد؛ تصمیم کاملاً بدون خطا نیست
حروف اختصاصی فارسی	fine-tune مدل عربی با داده فارسی و نمونه‌های هدفمند گ، ژ، پ و چ	بهبود یافت؛ نیازمند داده واقعی بیشتر است
overfitting	انتخاب checkpoint با validation و مقایسه روی Stage 2، PTDR و PersianOCR-1K	ادامه صرف epoch‌ها کنار گذاشته شد
دانه‌بندی متفاوت box‌ها	حفظ چهارضلعی‌های خام PP-OCrv6 و ارزیابی صریح با IoU	تقسیم یا ادغام برخی نواحی هنوز روی OCR انتهاییه‌انتهای اثر دارد

پیشنهادهای برای فاز بعد

۱. ساخت test set ثابت از تصاویر واقعی جدید، شامل متن‌های طولانی‌تر از ۳۲ نویسه.
۲. افزودن نمونه‌های واقعی بیشتر از حروف گ، ژ، پ و چ و خطاهای کم‌contrast، بدون تکرار داده‌های test.
۵. ارزیابی PTDR Detection برای کاهش وابستگی انتخاب مدل Detection به داده مرحله دوم.

فایل‌ها و لینک‌ها

منبع	نشانی
مخزن PTDR	https://github.com/zobeirraisi/PTDR
Persian-OCR-230k	https://huggingface.co/datasets/ordaktaktak/Persian-OCR-230k
اجرای محلی	README.md و مسیر http://127.0.0.1:8000
سوابق آزمایش	docs/experiments.md
لینک پروژه	https://github.com/AliNajafpour/tablokhan-ocr